

Week3_예습과제_백재은

Ch.4 / 분류

01. 분류의 개요

지도학습: 명시적인 정답이 있는 데이터(= 레이블)이 주어진 상태에서 학습하는 머신러닝 방식

분류(Classification): 지도학습의 대표 유형, 학습 데이터로 주어진 데이터의 피처와 레이블값(결정 값, 클래스 값)을 머신러닝 알고리즘으로 학습해 모델 생성, 해당 생성 모델에 새로운 데이터 값이 주어졌을 때 미지의 레이블 값 예측 -> 기존 데이터가 어떤 레이블에 속하는지 패턴을 알고리즘으로 인지, 새롭게 관측된 데이터에 대한 레이블 판별


머신 러닝 알고리즘: 나이브 베이즈, 로지스틱 회귀, 결정 트리, 서포트 벡터 머신, 최소 근접 알고리즘, 신경망, 앙상블

02. 결정 트리

• 개요

-> 데이터에 있는 규칙을 학습을 통해 자동으로 찾아내 트리 기반의 분류 규칙을 만드는 알고리즘

-> if/else 기반 분류 규칙



규칙 노드: 규칙 조건

리프 노드: 결정된 클래스 값

새로운 규칙 조건마다 서브 트리 생성

데이터 세트의 피처가 결합하여 규칙 조건을 만들 때마다 규칙 노드 생성 -> 많은 규칙 = 분류 결정 방식 복잡 up = 과적합 유발 -> 트리의 깊이가 깊어질 수록 결정 트리의 예측 성능 저하

-> 적은 결정 노드로 높은 예측 정확도

데이터 분류 시 최대한 많은 데이터 세트가 해당 분류에 속할 수 있도록 결정 노드 규칙 생성, 이때 최대한 균일한 데이터 세트를 구성할 수 있도록 분할하는 것이 필요

-> 데이터 세트의 균일도

데이터를 구분하는 데 필요한 정보의 양에 영향

결정 노드 -> 정보 균일도가 높은 데이터 세트 먼저 선택 규칙 조건 생성

= 정보 균일도가 데이터 세트로 쪼개질 수 있도록 조건 찾아 서브 데이터 세트 생성

= 해당 서브 데이터 세트에서 균일도가 높은 자식 데이터 세트 쪼개기

= 반복하며 데이터 값 예측

e.g. 엔트로피를 이용한 정보 이득 지수, 지니 계수

- 정보 이득 지수: 1에서 엔트로피(주어진 데이터 집합의 혼잡도) 지수를 뺀 값($= 1 - \text{엔트로피 지수}$) / 엔트로피가 높을 수록 서로 다른 값이 섞여 있음, 결정 트리의 분할 기준, 정보 이득이 높은 속성을 기준으로 분할
- 지니 계수: 경제학에서 불평등 지수를 나타낼 때 사용하는 계수, 0이 가장 평등 - 1로 갈 수록 불평등, 지니 계수가 낮을수록 데이터 균일도가 높은 것으로 해석 - 계수가 낮은 속성을 기준으로 분할

-> 사이킷런에서 결정 트리 알고리즘 구현: `DecisionTreeClassifier` = 지니 계수 이용 데이터 세트 분할. 정보 이득이 높거나 지니 계수가 낮은 조건을 찾아 자식 트리 노드에 걸쳐 반복 불한, 데이터가 모두 특정 분류에서 속하게 되면 분할 quit, 분류 결정

• 결정 트리 모델의 특징

장점: 정보의 균일도라는 룰을 기반으로 하여 알고리즘이 쉽고 직관적, 전처리 작업 필요 X

단점: 과적합으로 정확도 떨어짐 - 트리의 크기를 사전에 제한하는 튜닝 필요

• 결정 트리 파라미터

`DecisionTreeClassifier`: 분류를 위한 클래스

`DecisionTreeRegressor`: 회귀를 위한 클래스

CART: 사이킷런 결정 트리 구현 시 기반 트리 알고리즘

사용 파라미터

- `min_samples_split`, `min_samples_leaf`, `max_features`, `max_depth`, `max_leaf_nodes`

03. 앙상블 학습

• 개요

앙상블 학습을 통한 분류: 여러 개의 분류기 생성, 예측 결합을 통해 정확한 최종 예측 도출 기법

Goal: 단일 분류기보다 신뢰성이 높은 예측값 도출

효과: 정형 데이터 분류 시 뛰어난 성능

종류: 랜덤 포레스트, 그래디언트 부스팅 알고리즘 등

신규 알고리즘: XGBoost, LightGBM, Stacking

유형: 보팅, 배깅, 부스팅

	보팅	배깅
유사점	여러 개의 분류기가 투표를 통해 최종 예측 결과 결정	
차이점	일반적으로 서로 다른 알고리즘을 가진 분류기가 결합 -> 선형 회귀, K 최근접 이웃, 서포트 벡터 머신	각각의 분류기가 모두 같은 유형의 알고리즘 기반, 데이터 샘플링을 다르게 가져가 학습 수행 E.g. 랜덤 포레스트 알고리즘

부스팅: 여러 개의 분류기가 순차적으로 학습을 수행하되, 앞에서 학습한 분류기가 예측이 틀린 데이터에 대해서는 올바르게 예측할 수 있도록 다음 분류기에게 가중치 부여하면서 학습과 예측 진행

E.g. 그라디언트 부스트, XGBoost, LightGBM

스태킹: 여러 가지 다른 모델의 예측 결과값을 다시 학습 데이터화하여 다른 모델로 재학습시켜 결과 예측

• 보팅 유형

- 하드 보팅

다수결 원칙과 유사

예측한 결과값 중 다수의 분류기가 결정학 예측값을 최종 보팅 결과값으로 선정

- 소프트 보팅 (일반적으로 적용되는 방법)

분류기들의 레이블 값 결정 확률을 모두 더하고, 이를 평균하여 이들 중 확률이 가장 높은 레이블 값을 최종

보팅 결과값으로 선정

하드 보팅보다 주로 예측 성능 좋음

04. 랜덤 포레스트

• 개요

배깅: 같은 알고리즘으로 여러 개의 분류기를 만들어 보팅으로 최종 결정하는 알고리즘

랜덤 포레스트 특징: 앙상블 알고리즘 중 비교적 빠른 수행 속도, 다양한 영역에서 높은 예측 성능, 기반 알고리즘은 결정 트리

과정: 여러 개의 결정 트리 분류기가 전체 데이터에서 배깅 방식으로 각자의 데이터를 샘플링해 개별적으로 학습을 수행한 뒤, 최종적으로 모든 분류기가 보팅을 통해 예측 결정

-> 개별 분류기의 기반 알고리즘 = 결정 트리, 개별 트리가 학습하는 데이터 세트 = 전체 데이터에서 일부가 중첩되게 샘플링된 데이터 세트 (= 부스트 래핑 분할 방식)

-> 서브 세트 데이터 건수 = 전체 데이터 건수, 개별 데이터가 중첩되어 만들어짐

- 랜덤 포레스트 하이퍼 파라미터 및 튜닝

-> 트리 기반 앙상블 알고리즘의 단점: 하이퍼 파라미터가 많아 튜닝을 위한 시간이 많이 소모, 그에 반해 예측 성능 향상이 적음

-> 하이퍼 파라미터: `n_estimators`, `max_features`, `max_depth`, `min_sample`, `min_samples_split`