

Week13_예습과제_고은비

8.6 토픽 모델링 - 20 뉴스그룹


- 토픽 모델링 : 문서 집합에 숨어있는 주제를 찾아내는 것
 - LSA 기법
 - LDA (Latent Dirichlet Allocation) 기법
- 20 뉴스그룹 데이터 세트 적용
 - 20가지의 주제를 가진 뉴스그룹의 데이터를 가지고 있음
- LDA
 - 사이킷런은 LDA 기반의 토픽 모델링을 LatentDirichletAllocation 클래스로 제공함

8.7 문서 군집화 소개와 실습

- 문서 군집화 : 비슷한 텍스트 구성의 문서를 군집화하는 것
 - 텍스트 분류 기반의 문서 분류와 유사
 - 하지만 학습 데이터 세트가 필요 없는 비지도 학습 기반으로 동작
- Opinion Review 데이터 세트
 - Tripadvisor (호텔), Edmunds.com(자동차), Amazon.com(전자제품) 사이트의 리뷰 문서


8.8 문서 유사도

- 문서 유사도 측정 방법 - 코사인 유사도



벡터와 벡터간의 유사도를 비교할 때 벡터의 상호 방향성이 얼마나 유사한지에 기반해 두 벡터의 사잇각을 구해서 수치로 적용

- 두 벡터 사잇각



→ 이처럼 유사하거나 관련이 없거나 아예 반대 관계가 될 수 있음

$$\text{similarity} = \cos \theta = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$

두 벡터의 내적을 총 벡터 크기의 합으로 나눈 값이 유사도가 됨

- 가장 많이 사용되는 이유
 - 문서를 피쳐 벡터화 변환하면 차원이 매우 많은 희소 행렬이 되기 쉬움. 이러한 희소 행렬 기반에서 유클리드 거리 기반의 지표는 정확도가 떨어지기 쉽다.
 - 문서가 매우 긴 경우 단어의 빈도수가 더 많아 빈도수에만 기반해서는 공정한 비교를 할 수 없음

8.9 한글 텍스트 처리 - 네이버 영화 평점 감정 분석

- 한글 NLP 처리의 어려움
 - 띄어쓰기
 - 한글은 띄어쓰기를 잘못하면 의미가 왜곡되어 전달될 수 있음. 띄어쓰기 조건도 까다로움
 - 다양한 조사
 - 주어나 목적어를 위해 추가되며, 워낙 경우의 수가 많기 때문에 어근 추출 등 전처리할 때 제거하기가 까다로움
- ⇒ 라틴어 계열의 언어보다 NLP 처리가 어려운 문제가 있음

- KoNLPy

파이썬의 대표적인 한글 형태소(단어로서 의미를 가지는 최소 단위) 패키지

- 형태소 분석 : 말뭉치를 이러한 어근 단위로 쪼개고 각 형태소에 품사 태깅을 부착하는 작업을 지칭
- 기존의 C/C++, Java로 만들어진 한글 형태소 엔진을 파이썬 래퍼 기반으로 재작성한 패키지
- 자바가 먼저 설치되어 있어야 함
- 5개의 분석 모듈을 모두 사용 가능
- Mecab은 윈도우에서 구동되지 않음