



Week16_예습과제_고은비

ch09 추천 시스템

추천 시스템의 개요와 배경

개요

- 추천 시스템은 전자상거래, 유튜브, 음악 서비스 등에서 사용자 취향에 맞춘 상품·콘텐츠를 제공
- 기업은 추천 시스템으로 매출과 사용자 만족도를 높임
- 추천 엔진이 고도화될수록 개인화된 추천이 정교해짐
- 사용 이력에 따라 맞춤형 콘텐츠가 추천되고, 메인 화면도 취향에 맞게 변화함
- 효과적인 추천 시스템은 고객 만족도와 재구매율, 매출 증가에 직접적으로 기여
- 추천 시스템이 없는 경우, 고객은 원하는 상품을 찾기 어려워 이탈 가능성이 높아짐
⇒ 추천 엔진의 도입은 온라인 스토어의 경쟁력 강화와 차별화에 필수적

유형

- 콘텐츠 기반 필터링
- 협업 필터링
 - Nearest Neighbor
 - Latent Factor

초기에는 콘텐츠 기반이나 최근접 이웃 방식이 주로 사용 ⇒ 최근에는 행렬 분해(Matrix Factorization) 기반의 잠재 요인 협업 필터링이 대형 온라인 스토어에서 주로 활용 + 하이브리드 추천 시스템

콘텐츠 기반 필터링 추천 시스템

: 사용자가 특정 아이템을 좋아하면, 비슷한 속성의 다른 아이템을 추천하는 방식

- 아이템의 장르, 감독, 배우, 키워드 등 콘텐츠의 특징을 분석해 추천에 활용
- 각 아이템(영화 등)은 장르, 감독, 배우, 키워드 등 다양한 속성으로 프로파일링
- 사용자의 선호도 프로파일을 만들어 유사한 속성의 콘텐츠를 추천
- 장점: 새로운 아이템도 추천 가능, 사용자의 명확한 취향 반영
- 단점: 사용자가 경험하지 않은 속성은 추천에 한계가 있음, 취향이 다양할수록 정확도 저하 가능

최근접 이웃 협업 필터링

사용자의 행동(영화 평점, 구매 이력 등)을 기반으로, 나와 비슷한 취향의 사용자나 내가 좋아한 아이템과 유사한 아이템을 찾아 추천하는 방식

- 구조

사용자-아이템 평점 행렬(테이블)로 데이터를 구성

- 행(Row): 사용자
- 열(Column): 아이템
- 값: 평점 등 사용자 행동 데이터

로우 레벨 형태의 사용자 - 아이템 평점 데이터

UserID	Item ID	Rating
User 1	Item 1	3
User 1	Item 3	3
User 2	Item 1	4
User 2	Item 2	1
User 3	Item 4	5

변환

사용자 로우, 아이템 칼럼으로 구성된 사용자 - 아이템 평점 데이터

	Item 1	Item 2	Item 3	Item 4
User 1	3		3	
User 2	4	1		
User 3				5


대부분의 값이 비어 있는 희소 행렬(Sparse Matrix)

- 방식
 - 사용자 기반 : 나와 비슷한 사용자를 찾아, 그들이 좋아한 아이템을 추천
 - 아이템 기반 : 사용자가 좋아한 아이템과 유사한 아이템을 추천
- 과정
 1. 사용자-아이템 평점 데이터로 행렬 생성
 2. 유사도(Similarity) 계산을 통해 나와 유사한 사용자(또는 아이템) Top-N 선정
 3. 이웃의 평점/구매 이력을 바탕으로 내가 경험하지 않은 아이템을 추천
- 특징
 - 메모리 기반(Memory-based) 협업 필터링
 - 대규모 데이터에서 희소성(sparsity) 문제가 발생
 - 사용자 기반, 아이템 기반 모두 실제 온라인 서비스에서 널리 활용

잠재 요인 협업 필터링

: 사용자-아이템 평점 행렬을 기반으로, 사용자의 취향과 아이템의 특성을 설명하는 '잠재 요인(latent factor)'을 추출해 추천에 활용하는 방식

- 평점 행렬은 대부분 비어 있는 희소 행렬이므로, 이를 저차원 잠재 요인 공간으로 분해(행렬 분해)하여 효율적으로 사용함
- 대표적인 행렬 분해 방식으로 SVD, Matrix Factorization 등
- 행렬 분해 구조
 - 사용자-아이템 평점 행렬(R)을 두 개의 저차원 행렬로 분해:
 - 사용자-잠재 요인 행렬(P)
 - 아이템-잠재 요인 행렬(Q)
 - $R \approx P \times Q^T$ 형태로 표현
 - 각 행렬의 잠재 요인 값은 사용자의 취향(예: 액션, 로맨스 등)과 아이템의 특성(예: 영화의 장르별 요소)을 수치로 나타냄.



- 추천 예측 과정


- 사용자가 평가하지 않은 아이템의 평점을 예측하려면, 해당 사용자의 잠재 요인 벡터와 아이템의 잠재 요인 벡터의 내적을 계산함.
- 예시:
 - User1의 'Action' 선호도는 0.94, 'Romance' 선호도는 0.96
 - Item1(영화)의 'Action' 요소는 1.7, 'Romance' 요소는 2.49
 - 예측 평점 = $(0.94 \times 1.7) + (0.96 \times 2.49) = 4.0$ (실제 평점과 유사하게 예측)

• 특징

- 잠재 요인 기반 추천은 명시적으로 드러나지 않는 사용자의 취향과 아이템의 특성을 효과적으로 반영
- 희소한 평점 데이터에서도 추천 정확도를 높일 수 있음
- 행렬 분해로 데이터 저장 공간을 절약할 수 있음

행렬 분해

사용자-아이템 평점 행렬($R, M \times N$)을 저차원 잠재 요인(latent factor) 행렬($P, M \times K$)과 아이템 요인 행렬($Q, K \times N$)로 분해



- $R \approx P \times Q^T$ 형태로 근사, K는 잠재 요인 개수.
- P의 각 행은 사용자별 잠재 요인 벡터, Q의 각 행은 아이템별 잠재 요인 벡터
- 이 분해를 통해 희소한 평점 행렬에서 숨겨진 패턴(취향, 특성 등)을 추출
- 구조
 - $R(\text{사용자} \times \text{아이템})$ 행렬을 $P(\text{사용자} \times \text{잠재요인})$, $Q(\text{아이템} \times \text{잠재요인})$ 행렬로 분해
 - 예시:
4명 사용자, 5개 아이템, 2개 잠재 요인($K=2$)일 때, $R(4 \times 5) \approx P(4 \times 2) \times Q^T(2 \times 5)$

R(4 X 5)					
	Item 1	Item 2	Item 3	Item 4	Item 5
User 1	4			2	
User 2		5		3	
User 3			3	4	4
User 4	5	2	1	2	

P(4 X 2)		
	factor 1	factor 2
User 1	0.94	0.96
User 2	2.14	0.08
User 3	1.93	1.79
User 4	0.58	1.59

Q.T(2 X 4)					
	Item 1	Item 2	Item 3	Item 4	Item 5
factor 1	1.7	2.3	1.41	1.36	0.41
factor 2	2.49	0.41	0.14	0.75	1.77

개별 Row는 개별 User에 대한 Latent Factor들을 반영
개별 Column은 개별 item에 대한 Latent Factor들을 반영

- 사용자별 잠재 요인 벡터(P의 행)와 아이템별 잠재 요인 벡터(Q의 행)를 내적해 예측 평점 계산


$r(2, 4)$					
	Item 1	Item 2	Item 3	Item 4	Item 5
User 1	4			2	
User 2		5		3	
User 3			3	4	4
User 4	5	2	1	2	

p_2		
	factor 1	factor 2
User 1	0.94	0.96
User 2	2.14	0.08
User 3	1.93	1.79
User 4	0.58	1.59


q_4^t					
	Item 1	Item 2	Item 3	Item 4	Item 5
factor 1	1.7	2.3	1.41	1.36	0.41
factor 2	2.49	0.41	0.14	0.75	1.77

$\hat{r} = 2.14 \times 1.36 + 0.08 \times 0.75 = 2.97$

- 사용자가 평가하지 않은 아이템의 평점도 잠재 요인 행렬 내적($P \times Q^T$)으로 예측 가능



예측 평점 행렬($R^{\wedge}$)을 통해 사용자-아이템 모든 조합의 평점을 계산, 추천에 활용



- SGD 기반 행렬 분해 절차
 - P, Q 행렬을 임의의 값으로 초기화
 - 실제 평점과 예측 평점의 오차를 계산해, P, Q 행렬을 반복적으로 업데이트
 - 업데이트 식:
 - L2규제를 고려한 비용함수 식

$$\min \sum (r_{(u,i)} - p_u q_i^t)^2 + \lambda (\|q_i\|^2 + \|p_u\|^2)$$

- 업데이터터 식

$$\begin{aligned} \dot{p}_u &= p_u + \eta (e_{(u,i)} * q_i - \lambda * p_u) \\ \dot{q}_i &= q_i + \eta (e_{(u,i)} * p_u - \lambda * q_i) \end{aligned}$$

람다 : L2 규제 계수

뮤 : SGD 학습률

⇒ 행렬 분해는 희소한 평점 행렬을 저차원 잠재 요인 공간으로 분해해, 미평가 아이템의 평점을 효과적으로 예측하는 추천 시스템의 핵심 기법

파이썬 추천 시스템 패키지 - Surprise

Surprise는 협업 필터링, 아이템 기반/사용자 기반 필터링, 잠재 요인 기반 행렬 분해 등 다양한 추천 알고리즘을 간편하게 구현할 수 있는 파이썬 라이브러리

- 다양한 추천 시스템 알고리즘을 코드 몇 줄로 실행할 수 있도록 설계됨
- 데이터셋 로딩, 모델 학습, 예측, 평가 등 추천 시스템 개발에 필요한 기능을 API로 제공

Surprise 주요 모듈 소개

- Dataset
 - Surprise는 기본적으로 user_id(사용자 아이디), item_id(아이템 아이디), rating(평점) 정보를 필수로 요구
 - 추가적으로 time_stamp(타임스탬프) 등 다른 컬럼이 있어도, 실제로는 앞의 세 컬럼만 사용
 - 데이터는 반드시 '사용자 아이디, 아이템 아이디, 평점' 순서로 정렬되어야 하며, 이 순서가 맞지 않으면 오류가 발생할 수 있음

API 명	내용
Dataset.load_builtin (name='ml-100k')	무비렌즈 아카이브 FTP 서버에서 무비렌즈 데이터를 내려받습니다. ml-100k, ml-1M를 내려받을 수 있습니다. 일단 내려받은 데이터는 .surprise_data 디렉터리 밑에 저장되고, 해당 디렉터리에 데이터가 있으면 FTP에서 내려받지 않고 해당 데이터를 이용합니다. 입력 파라미터인 name으로 대상 데이터가 ml-100k인지 ml-1m인지를 입력합니다(name='ml-100k'). 디폴트는 ml-100k입니다.

API 명	내용
Dataset.load_from_file (file_path, reader)	OS 파일에서 데이터를 로딩할 때 사용합니다. 콤마, 탭 등으로 칼럼이 분리된 포맷의 OS 파일에서 데이터를 로딩합니다. 입력 파라미터로 OS 파일명, Reader로 파일의 포맷을 지정합니다.
Dataset.load_from_df (df, reader)	판다스의 DataFrame에서 데이터를 로딩합니다. 파라미터로 DataFrame을 입력받으며 DataFrame 역시 반드시 3개의 칼럼인 사용자 아이디, 아이템 아이디, 평점 순으로 칼럼 순서가 정해져 있어야 합니다. 입력 파라미터로 DataFrame 객체, Reader로 파일의 포맷을 지정합니다.

Surprise 추천 알고리즘 클래스

클래스명	설명
SVD	행렬 분해를 통한 잠재 요인 협업 필터링을 위한 SVD 알고리즘.
KNNBasic	최근접 이웃 협업 필터링을 위한 KNN 알고리즘.
BaselineOnly	사용자 Bias와 아이템 Bias를 감안한 SGD 베이스라인 알고리즘.

- SVD 클래스의 입력 파라미터

파라미터명	내용
n_factors	잠재 요인 K의 개수. 디폴트는 100. 커질수록 정확도가 높아질 수 있으나 과적합 문제가 발생할 수 있습니다.
n_epochs	SGD(Stochastic Gradient Descent) 수행 시 반복 횟수, 디폴트는 20.
biased (bool)	베이스라인 사용자 편향 적용 여부이며, 디폴트는 True입니다.

튜닝 효과는 크지 않음

- 추천 알고리즘 예측 성능 벤치마크 결과


알고리즘 유형	RMSE	MAE	Time
SVD	0.934	0.737	0:00:11
SVD++	0.92	0.722	0:09:03
NMF	0.963	0.758	0:00:15
Slope One	0.946	0.743	0:00:08
k-NN	0.98	0.774	0:00:10
Centered k-NN	0.951	0.749	0:00:10
k-NN Baseline	0.931	0.733	0:00:12
Co-Clustering	0.963	0.753	0:00:03
Baseline	0.944	0.748	0:00:01

- SVD++ 알고리즘
 - RMSE, MAE 등 성능 지표가 가장 우수함
 - 단점: 연산 시간이 오래 걸려 대용량 데이터에는 실용성이 떨어질 수 있음
- SVD, k-NN Baseline
 - SVD++를 제외하면 SVD와 k-NN Baseline이 가장 좋은 성능 평가 수치(RMSE, MAE 등)를 보임
- k-NN 단독 vs Baseline 결합

- k-NN 단독 사용 시 성능이 상대적으로 낮음.
- Baseline과 결합하면 성능 평가 수치가 크게 향상
- Baseline :
 - 각 개인이 평점을 부여하는 경향(성향)을 반영해 평점을 계산하는 방식
 - 평점 예측에 Baseline을 결합하는 방식이 성능 개선에 효과적

베이스라인 평점

사용자가 한 번도 평점을 매기지 않은 아이템에 대해 예상 평점을 어떻게 산출할지에 대한 기준이 필요 ⇒ 일부 사용자는 평점이 전반적으로 높거나 낮은 경향(성향)을 보이므로, 단순 평균만으로는 편향이 발생할 수 있음
⇒ 이런 편향을 보정하기 위해 '베이스라인 평점'을 도입



평점 산출 공식

- 전체 평균 평점(모든 사용자와 아이템에 대한 평균)
 - 사용자 편향(특정 사용자가 평균적으로 주는 평점의 경향)
 - 아이템 편향(특정 아이템이 평균적으로 받는 평점의 경향)
- ⇒ 베이스라인 평점=전체 평균 평점+사용자 편향+아이템 편향

정리

추천 시스템은 기업 애플리케이션에서 매우 중요한 역할을 하며, 특히 온라인 스토어에서 매출 향상과 이용자 만족도 증대에 기여

주요 추천 방식

- 콘텐츠 기반 필터링
 - 사용자가 선호하는 콘텐츠의 속성을 분석해 유사한 속성의 다른 아이템을 추천
- 협업 필터링:
 - 최근에는 협업 필터링이 많이 활용됨
 - 사용자 기반(비슷한 사용자가 좋아한 아이템 추천)과 아이템 기반(비슷한 아이템 추천)으로 나뉨
 - 사용자-아이템 평점 행렬(희소 행렬)에서 유사한 사용자 또는 아이템을 찾아 추천
 - Top-N 방식으로 유사도가 높은 이웃의 평가를 바탕으로 추천 결과 도출
 - 사용자 기반은 비슷한 사용자들의 평가를 참고, 아이템 기반은 비슷한 아이템을 추천

잠재 요인 협업 필터링

- 사용자의 명시적 평가가 많지 않아도, 행렬 분해(잠재 요인 추출) 기법을 통해 추천의 정확도를 높임
- SVD 등 행렬 분해 기법을 활용해 사용자와 아이템의 숨겨진 특성을 추출

Surprise 패키지

- 파이썬 기반 추천 시스템 패키지로 다양한 추천 알고리즘을 쉽게 실습할 수 있음
- Surprise는 실습에 필요한 데이터셋, 알고리즘, 평가 기능을 제공해 추천 시스템 실습에 유용